Reto 0 : ANÁLISIS IA

Monitorización de los robots del aula con Node-RED, InfluxDB y Grafana

Equipo Smartek
Jon, Julen, Naiara

Especialización en IA y Big Data · Octubre de 2026



SmarTek
AI & SMART ROBOTICS

ÍNDICE

1. Comprensión del Problema del Cliente....3
   1.1. Análisis de datos disponibles por activo....3
   1.2. Mejoras, objetivos y datos clave....3
   1.3. Fundamentos de IA y tipos de tarea predictiva....3
2. Análisis de Aplicaciones de IA en el Sector....4
   2.1. Mantenimiento Predictivo y Control de Calidad....4
   2.2. Optimización de Flotas y Logística Interna (robots MiR)....4
3. Identificación de técnicas y modelos....5
   Alternativa 1 (seleccionada): Mantenimiento predictivo en impresoras 3D....5
   Alternativa 2 (descartada): Optimización de misiones para los robots MiR....5
   3.1. Caracterización técnica de los modelos....5
   3.2. Comparación de requisitos....5
4. Selección y Justificación del Modelo Adecuado....6
   4.1.Modelo seleccionado: Alternativa 1, mantenimiento predictivo en impresoras 3D con LSTM-Autoencoder....6
5. Diseño de la solución....6
6. Análisis del Impacto....7
   6.1. Proceso que se mejora....7
   6.2. Cómo mejora la eficiencia....7
   6.3. Ventajas....7
   6.4. Limitaciones....7
   6.5. Riesgos a tener en cuenta....7

1. Comprensión del Problema del Cliente

1.1. Análisis de datos disponibles por activo

La célula de fabricación genera datos continuos en tiempo real con tres tipos de activos:

ACTIVO	DATOS	PROBLEMAS DETECTADOS
2 impresoras 3D	Temperaturas (boquilla/cama), coordenadas (X,Y,Z), consumo del extrusor, velocidad y vibraciones.	Atascos de filamento, fallos de adherencia, desgaste térmico e impresiones defectuosas.
2 AMRs MiR	Coordenadas (X,Y), batería, velocidad, distancia recorrida, historial y estado de misiones y misiones en cola.	Batería insuficiente, obstáculos en el trayecto hacia la misión.
1 Brazo Dobot	Posiciones articulares/cartesianas, ciclos pick-and-place, consumo de servomotores, presión de agarre del gripper.	Descalibración por pequeños impactos y fatiga en los servomotores.

1.2. Mejoras, objetivos y datos clave

- Mejoras con IA: Digitaliza la planta pasando de un mantenimiento reactivo a uno predictivo para reducir costes y paradas.
- Objetivos: Predecir averías, detener impresiones defectuosas al instante para no tirar material y reasignar tareas vía IoT sin supervisión humana constante.
- Datos relevantes: Series temporales a alta frecuencia (temperaturas, consumos y vibraciones) e histórico de logs (fallos, mantenimientos, errores y materiales).

1.3. Fundamentos de IA y tipos de tarea predictiva

La IA permite a las máquinas percibir, aprender y decidir. El Machine Learning aprende de datos en lugar de seguir reglas programadas, y puede ser:

- **Supervisado:** Aprende de ejemplos con la respuesta correcta.
- **No supervisado**: Encuentra patrones sin respuestas.
- **Por refuerzo**: Aprende a decidir mediante recompensas.

En mantenimiento predictivo hay tareas distintas: la detección de anomalías avisa cuando la máquina se sale de lo normal y solo necesita datos normales; la clasificación de fallos identifica el tipo de fallo y necesita muchos fallos etiquetados; la estimación de vida útil

predice cuánto falta para el fallo y necesita historiales completos; y el aprendizaje por refuerzo decide acciones, como el reparto de misiones de los MiR.

Nuestro problema es la detección de anomalías, porque la célula no tiene un historial amplio de fallos etiquetados.

2. Análisis de Aplicaciones de IA en el Sector

En la Industria 4.0, la IA se centra en dos grandes áreas:

2.1. Mantenimiento Predictivo y Control de Calidad

- **Problema que resuelve:** Detecta averías en piezas clave (como la boquilla), fallos en el material o desajustes mecánicos antes de estropear la pieza.
- **Beneficios:** Reduce los costes de reparación, evita tirar filamento y aprovecha al máximo las máquinas.
- **Técnicas aplicadas:**
  i. *Autoencoders: Aprenden el funcionamiento normal de la máquina y avisan si detectan un dato "raro" o anómalo.*
  ii. Redes LSTM: Analizan datos que cambian con el tiempo para predecir fallos futuros mirando el historial reciente.
  iii. Algoritmos de clasificación de patrones sobre series temporales (*XGBoost*, *Random Forest*).
- **Caso documentado:** Obico (antes The Spaghetti Detective) usa IA para analizar la webcam de la impresora y detectar fallos como hilos sueltos o despegue de la pieza. Cuando detecta uno, pausa la impresión y evita gastar más filamento y tiempo.

2.2. Optimización de Flotas y Logística Interna (robots MiR)

- **Problema que resuelve:** atascos en puntos de paso, mal reparto de misiones entre robots y batería agotada a mitad de tarea.
- **Beneficios:** transportes más rápidos, trabajo repartido entre los robots y rutas más cortas.
- **Técnicas aplicadas:** Aprendizaje por refuerzo (RL), que aprende por prueba y error qué decisión tomar, y algoritmos de búsqueda de rutas (A, Dijkstra) para elegir el camino más corto.
- **Caso documentado:** FORVIA usa 14 robots MiR en su planta de la República Checa, gestionados con MiR Fleet. Ha aumentado su productividad logística y ha recuperado la inversión en menos de dos años.

3. Identificación de técnicas y modelos

Para detectar fallos y comportamientos anómalos en los robots y las impresoras a partir de sus datos (temperatura, batería, tiempos...), consideramos dos alternativas:

Alternativa 1 (seleccionada): Mantenimiento predictivo en impresoras 3D

- Modelo: LSTM-Autoencoder
- Objetivo: Predecir fallos y atascos.
- Adecuación: antes de un atasco, la temperatura y la corriente del extrusor cambian ligeramente y el modelo detecta ese cambio. No necesita fallos para entrenarse, pero sí unos pocos reales o provocados para validar que los detecta a tiempo.

Alternativa 2 (descartada): Optimización de misiones para los robots MiR

- Modelo: Deep Q-Network (DQN)
- Objetivo: Rutas y asignación de misiones
- Adecuación: reparte el transporte entre impresoras y brazo Dobot cuando la demanda cambia, adaptando la ruta de los 2 MiR.

3.1. Caracterización técnica de los modelos

LSTM-Autoencoder (no supervisado): reconstruye las series de los sensores y detecta anomalías por el error de reconstrucción. Tiene en cuenta la evolución temporal y se entrena sin fallos.

Random Forest y XGBoost (supervisados): combinan árboles de decisión, en paralelo (RF) o en secuencia corrigiendo errores (XGBoost), para clasificar el tipo de fallo. Necesitan muchos fallos etiquetados.

DQN (aprendizaje por refuerzo): una red neuronal aprende por prueba y error qué acción da más recompensa. Decide acciones en lugar de detectar fallos y necesita un simulador para entrenarse.

3.2. Comparación de requisitos

Alternativa 1: necesita datos de funcionamiento normal y la infraestructura existente.

Alternativa 2: necesita un simulador, una función de recompensa y un entrenamiento largo.

4. Selección y Justificación del Modelo Adecuado

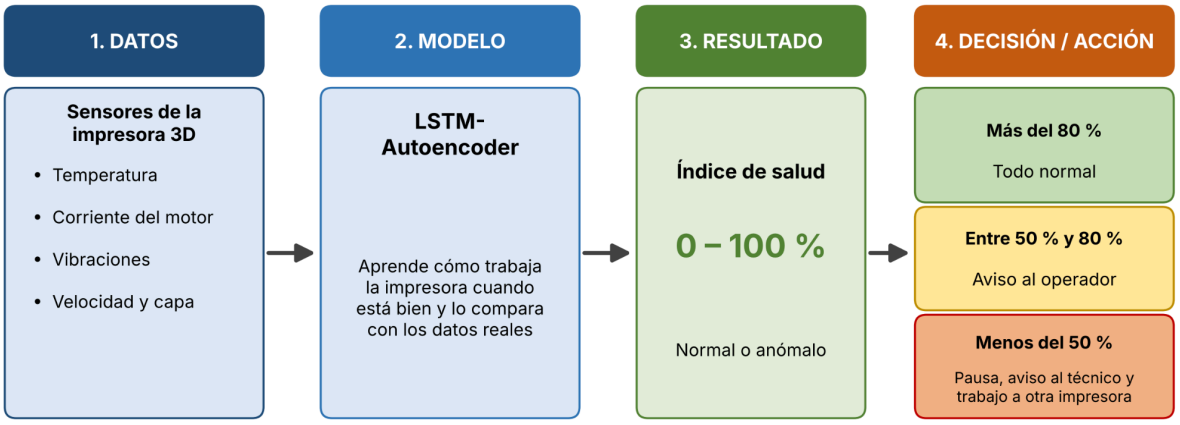
4.1.Modelo seleccionado: Alternativa 1, mantenimiento predictivo en impresoras 3D con LSTM-Autoencoder.

- Un fallo no detectado en una impresión larga invalida toda la pieza y malgasta energía, horas de máquina y filamento.
- Datos: series temporales en JSON o CSV, resumidas en un valor por segundo y agrupadas en bloques de 5 minutos.
- Entrada: temperatura del extrusor y de la cama, consumo del motor, vibraciones, velocidad, capa, material y tipo de pieza.
- Resultado: índice de salud (0–100 %). Se entrena solo con impresiones correctas y se comprueba provocando fallos.
- Decisión:
  - Más del 80 %: funcionamiento normal.
  - Entre 50 % y 80 %: aviso al operador.
  - Menos del 50 %: pausa, aviso al técnico y trabajo a la otra impresora.

El 80 % se fija donde casi ninguna impresión correcta llega, y el 50 % donde aparecen los fallos provocados; ambos se revisan si hay muchas falsas alarmas. Una parada innecesaria solo cuesta el tiempo de revisión. Según estudios de Cambridge, la corriente y las vibraciones cambian antes del atasco, y el modelo solo se usa si mejora a un límite fijo por señal.

Se descarta la Alternativa 2 porque con solo 2 robots MiR el reparto de misiones se resuelve con MiR Fleet, y el DQN añadiría complejidad innecesaria.

5. Diseño de la solución



Explicación de las etapas:

- **Datos:** las impresoras envían continuamente temperatura, consumo del motor, vibraciones, velocidad y capa.

- **Modelo:** los datos se escalan y se agrupan en ventanas de 5 minutos. El autoencoder los comprime y los reconstruye como serían con la máquina funcionando bien; sus capas son LSTM para tener en cuenta cómo cambian las señales con el tiempo. Cuanto más difiere lo real de lo reconstruido, mayor es el error.
- **Resultado:** el error se convierte en un índice de salud de 0 a 100 %.
- **Decisión**: según el índice, la impresora sigue, se avisa al operador o se pausa y el trabajo pasa a la otra impresora.

6. Análisis del Impacto

6.1. Proceso que se mejora

La fabricación de piezas con las impresoras 3D, y el tiempo que las máquinas están realmente disponibles para trabajar.

6.2. Cómo mejora la eficiencia

Se evitan bloqueos que nadie detecta, sobre todo de noche, y se desperdicia menos filamento. Con unas 160 impresiones al mes y un 8 % de fallos, detectar la mitad a tiempo ahorraría unas 20 horas de máquina y medio kilo de filamento al mes. Se medirá comparando un mes sin el sistema con un mes con él: impresiones fallidas, filamento desperdiciado, horas perdidas y falsas alarmas.

6.3. Ventajas

- Detecta fallos antes de que se vean a simple vista.
- Se puede ampliar a más impresoras sin rehacer la solución desde cero.
- Se integra con los sistemas que ya usa la fábrica (por ejemplo, mensajes MQTT).

6.4. Limitaciones

- Necesita datos de funcionamiento normal con distintos trabajos y materiales para aprender bien.
- No puede prever fallos repentinos que los sensores no registran, como la rotura del filamento fuera de su alcance.

6.5. Riesgos a tener en cuenta

- Falsas alarmas: pausar una impresora que funciona bien hace perder tiempo.
- Fallos no detectados: confiar demasiado en el sistema puede hacer que se descuiden las revisiones manuales.
- Cambios en las condiciones (nuevo material, nueva impresora): el modelo puede perder precisión y habrá que reentrenarlo.